

Capitolo 04 — Working Memory: la memoria viva

Pubblico	Lettori tecnici e non tecnici del WCM Process & Memory Book
Versione	FROZEN-04
Data master	2026-08-26
Stato	FROZEN
Source path	wcm/documentation/process-memory-book/chapters/04_working_memory.md
Source SHA	76c6a2d
Release	2026-08-31T20:48:50.990Z

GitHub main è la source of truth. Questo PDF è una release derivata: non costituisce approvazione né autorità.

Stato: FROZEN **Blocco:** 1 — Fondamenti + Dual Memory **Scope:** WCM generale / domain-agnostic **Technical Review:** PASS — 2026-08-26 **Human Comprehension Review:** PASS — 2026-08-26

4.0 Una memoria che serve a pensare, non a conservare tutto

Nel capitolo precedente abbiamo introdotto la Dual Memory Architecture e abbiamo visto perché WCM non affida tutta la continuità né alla conversazione corrente né alla sola memoria persistente.

Ora apriamo il primo dei due lati dell'architettura: la **Working Memory**, cioè la memoria viva del lavoro cognitivo corrente.

Per comprenderla conviene partire da un'esperienza molto comune.

Immaginiamo due persone che stanno lavorando insieme davanti a una lavagna. Parlano, cancellano una frase, aggiungono un vincolo, cambiano ordine alle priorità, formulano ipotesi e arrivano progressivamente a una conclusione.

Durante quella discussione entrambe possiedono qualcosa che nessun verbale scritto dopo riuscirebbe a riprodurre perfettamente: il filo del ragionamento ancora vivo.

Sanno, per esempio:

- che una certa idea era stata proposta soltanto per esplorarla;
- che una frase ironica non era una decisione;
- che un'obiezione appena sollevata cambia il senso di ciò che era stato detto cinque minuti prima;
- che una possibilità è ancora aperta;
- che una certa richiesta è urgente non perché esista già un documento che lo dichiara, ma perché il contesto della conversazione lo rende evidente;
- che una correzione appena formulata deve ancora essere consolidata.

Questa ricchezza contestuale assomiglia a ciò che WCM chiama **Working Memory / Interaction Memory**.

Non è semplicemente un elenco di messaggi.

È il contesto cognitivo vivo che consente al sistema di interpretare correttamente ciò che sta accadendo adesso.

La Working Memory è quindi preziosa proprio perché è vicina al pensiero in movimento.

Ed è per la stessa ragione che non può essere trattata come l'archivio definitivo dell'organizzazione.

4.1 Che cos'è la Working Memory

Nel WCM la **Working Memory** è l'insieme del contesto disponibile e pertinente durante il lavoro cognitivo corrente.

Può comprendere, quando il runtime lo rende disponibile:

- la conversazione attuale;
- chiarimenti recenti;
- intenzioni ancora vive;
- ragionamenti in corso;
- ipotesi non ancora risolte;
- correzioni appena formulate;
- cambi di idea non ancora consolidati;
- decisioni appena espresse che, se materiali, devono ancora essere classificate e consolidate;
- informazioni operative immediatamente necessarie al task corrente.

La parola **runtime**, in questo contesto, indica semplicemente l'ambiente tecnico nel quale quella specifica esecuzione sta avvenendo. Non è necessario conoscerne i dettagli per capire il principio: la Working Memory esiste finché quel contesto è effettivamente disponibile al sistema che sta lavorando.

Una definizione semplice può essere questa:

La Working Memory è ciò che il sistema ha mentalmente “sul tavolo” mentre sta comprendendo, ragionando e agendo.

Questa definizione è volutamente diversa da:

“tutto ciò che il sistema ha mai saputo”.

La Working Memory è **circoscritta al contesto attivo**. Contiene ciò che è disponibile e pertinente al lavoro corrente, non l'intera storia dell'organizzazione.

Ed è volutamente diversa anche da:

“tutto ciò che è vero”.

Nella memoria viva possono convivere fatti, dubbi, ipotesi, proposte e decisioni appena formulate. Il loro significato organizzativo deve ancora essere distinto.

FIG-001A — Dove si trova la Working Memory nella Dual Memory

FIG-001A — Dual Memory Architecture, versione semplice

La figura mostra il ruolo della Working Memory nel ciclo generale.

La memoria viva è il lato della **ricchezza semantica, dell'immediatezza e della sfumatura**.

La Persistent Organizational Memory è il lato della **durata, della struttura, dell'autorità e della storia**.

La Working Memory non è quindi “inferiore” alla memoria persistente. Svolge un lavoro diverso.

4.2 Cosa contiene davvero

Dire che la Working Memory contiene “la conversazione” è corretto, ma incompleto.

Per capire perché, consideriamo questa breve sequenza:

«Potremmo spostare la consegna a venerdì.» «No, aspetta: venerdì il cliente non è disponibile.» «Giusto. Allora lasciamo la data attuale.» «Però anticipiamo il controllo interno di un giorno.»

Le parole sono quattro messaggi distinti.

Il significato vivo, però, è qualcosa di più:

- esisteva una proposta di spostamento;
- è emerso un vincolo;
- la proposta è stata abbandonata;
- la data principale non cambia;
- nasce una nuova possibile modifica sul controllo interno.

La Working Memory mantiene il **contesto relazionale** tra questi elementi.

Per questo, nel WCM, la memoria viva può contenere almeno cinque famiglie di contenuti.

A. Contesto esplicito

È ciò che è stato detto o fornito direttamente:

- richieste;
- testi;
- numeri;
- file letti durante il task;
- istruzioni;
- correzioni.

B. Contesto conversazionale

È il significato che deriva dalla sequenza:

- a cosa si riferisce “quello”;
- quale proposta stiamo ancora discutendo;
- cosa è stato appena scartato;
- quale domanda stiamo realmente cercando di risolvere.

C. Contesto operativo immediato

Comprende ciò che serve per svolgere il passo corrente:

- il goal immediato;
- il punto del lavoro a cui siamo arrivati;
- l'output che stiamo preparando;
- eventuali vincoli appena verificati;
- le fonti già aperte e pertinenti.

D. Contenuti cognitivi non ancora consolidati

Sono elementi che hanno significato, ma non hanno ancora una collocazione organizzativa definitiva:

- riflessioni;
- ipotesi;
- alternative;
- bozze;
- interpretazioni;
- nuove decisioni ancora da registrare;
- nuove evidenze ancora da classificare.

E. Contesto persistente richiamato nel presente

La Working Memory può includere anche informazioni recuperate dalla memoria persistente per il task corrente.

Quando WCM legge, per esempio, una decisione attiva o un protocollo necessario, quella conoscenza entra temporaneamente nel contesto vivo per essere usata nel ragionamento.

Questo punto è importante:

Persistent Memory e Working Memory non sono stanze isolate. Una alimenta l'altra.

Un contenuto persistente può essere recuperato e diventare parte della Working Memory; un delta nato nella Working Memory può essere consolidato e diventare parte della memoria persistente.

4.3 Perché è semanticamente ricca

La Working Memory è particolarmente utile perché conserva qualcosa che una rappresentazione molto strutturata tende inevitabilmente a comprimere: **la sfumatura**.

Per “semantica” intendiamo il significato di ciò che viene detto o osservato, non soltanto la sua forma letterale.

La frase:

«Va bene, facciamo.»

presa da sola dice poco.

Per interpretarla correttamente dobbiamo sapere:

- a quale proposta risponde;
- chi la pronuncia;
- se quella persona possiede authority;
- se poco prima erano state discusse condizioni particolari;
- se “va bene” rappresenta approvazione definitiva o semplice disponibilità a esplorare l'opzione.

Il contesto vivo può contenere tutte queste sfumature contemporaneamente.

Questa densità semantica è uno dei motivi per cui WCM non vuole trasformare ogni conversazione in una serie di campi strutturati mentre il ragionamento è ancora in corso.

Strutturare troppo presto può far perdere significato.

Ma non strutturare mai produce il problema opposto: il significato resta legato alla sessione e può non sopravvivere.

La Dual Memory nasce anche per gestire questa tensione.

La Working Memory offre libertà cognitiva.

La memoria persistente offre stabilità organizzativa.

Il consolidamento è il passaggio nel quale il sistema decide quale parte della ricchezza viva deve diventare abbastanza strutturata da poter essere ritrovata e governata in futuro.

4.4 Perché è temporanea

La parola “temporanea” non significa che la Working Memory scompaia necessariamente dopo pochi minuti.

Significa che **WCM non può assumere che quel contesto rimarrà disponibile indefinitamente e nella stessa forma.**

Il contesto di lavoro può cambiare per molte ragioni:

- termina una conversazione;
- inizia una nuova sessione;
- il contesto tecnico disponibile viene ridotto;
- viene utilizzato un modello o un servizio differente;
- il lavoro passa a un'altra capacità;
- una lunga attività richiede di lasciare spazio a nuove informazioni;
- alcuni dettagli vengono sintetizzati o non sono più direttamente disponibili.

Qui compare un termine tecnico spesso usato con gli LLM: **context window**.

Possiamo immaginarla come la quantità di contesto che il modello può avere direttamente davanti a sé durante una specifica elaborazione.

Non è necessario conoscere il numero esatto di token o il meccanismo interno per comprendere il problema organizzativo.

Il punto è questo:

ciò che è visibile al sistema adesso non è garantito che resti visibile nello stesso modo in futuro.

Per questo WCM non usa la Working Memory come unica fonte di continuità.

Se qualcosa deve essere noto tra una sessione e l'altra, deve esistere un percorso affidabile per consolidarlo nella memoria persistente appropriata.

4.5 Cosa possiamo fidarci a lasciare nella Working Memory

Non tutto deve diventare un documento, un record o un nodo persistente.

Se WCM persistesse ogni pensiero, ogni tentativo e ogni frase, la memoria organizzativa diventerebbe rapidamente rumorosa e difficile da navigare.

Esistono quindi contenuti che possono ragionevolmente restare nella Working Memory quando non producono effetti durevoli.

Ragionamenti esplorativi

Per esempio:

| *«Proviamo a vedere se questa strada ha senso.»*

Il fatto di aver esplorato un'ipotesi non richiede automaticamente un record persistente.

Se l'ipotesi viene scartata senza generare conseguenze, può restare parte del percorso cognitivo temporaneo.

Tentativi locali e reversibili

Una formulazione provvisoria, un ordine temporaneo delle idee o una bozza che serve soltanto per arrivare a una versione successiva non devono necessariamente entrare nella memoria organizzativa.

Domande già risolte nel corso della stessa interazione

Una domanda può essere utile per il ragionamento senza costituire un elemento che l'organizzazione deve ricordare.

Dettagli che non cambiano stato, authority, requisiti o futuro

Molti particolari sono utili nel momento ma non hanno valore organizzativo durevole.

La regola generale non è:

| *“se è interessante, salvarlo”.*

È più vicina a:

| **“se una futura ripresa del lavoro ha bisogno di questo elemento per ricostruire correttamente stato, decisioni, vincoli, evidenze o continuità, allora deve essere valutato per il consolidamento.”**

Questa regola protegge la memoria persistente dal diventare una discarica della conversazione.

4.6 Cosa non possiamo affidare soltanto alla Working Memory

Qui il confine deve essere molto più rigoroso.

Alcuni elementi non possono rimanere soltanto nel contesto vivo quando producono effetti organizzativi durevoli.

Tra questi troviamo, quando materiali:

- decisioni;
- cambi di decisione;
- stato corrente;
- cambi di stato di un workflow;
- requisiti;
- vincoli;
- rischi rilevanti;
- assunzioni importanti;
- evidenze che modificano ciò che WCM sa;
- output approvati, frozen o locked;
- authority necessaria a una transizione;
- checkpoint di workflow;
- learning che può diventare rilevante per il metodo;
- relazioni e dipendenze che devono essere ricordate.

Perché?

Perché se uno di questi elementi resta soltanto nella conversazione corrente, una sessione futura potrebbe non sapere che esiste.

Consideriamo una decisione semplice:

| «Da oggi il limite è 50.»

Se questa frase produce una vera decisione autorizzata, lasciare l'informazione soltanto nella Working Memory significa affidare una regola futura alla sopravvivenza di quella specifica conversazione.

WCM vuole invece che una futura sessione possa ricostruire almeno:

- qual è la decisione corrente;
- chi aveva authority per prenderla;
- quando è diventata valida;
- cosa eventualmente sostituisce;
- quali elementi dipendono da essa.

Lo stesso principio vale per un workflow.

Se un processo è arrivato a una transizione materiale e la sessione termina, il sistema non deve affidarsi alla memoria viva per sapere dove ripartire. Il checkpoint persistente deve rappresentare il punto raggiunto.

La Working Memory può sapere perfettamente dove siamo.

Ma se quella conoscenza deve sopravvivere, **sapere non basta: bisogna consolidare.**

4.7 Riflessione, ipotesi, proposta, decisione: non sono la stessa cosa

Questa è una delle distinzioni più importanti dell'intera architettura.

La Working Memory è il luogo nel quale contenuti con forza organizzativa molto diversa possono apparire uno accanto all'altro.

Consideriamo quattro frasi:

- | «Mi chiedo se X possa funzionare.»
- | «Secondo me X potrebbe funzionare.»
- | «Propongo di adottare X.»
- | «Decidiamo di adottare X.»

A prima vista parlano tutte di X.

Organizzativamente, però, sono diverse.

Riflessione

Una riflessione apre uno spazio mentale.

Non stabilisce che qualcosa sia vero e non chiede necessariamente un'azione.

Ipotesi

Un'ipotesi propone una spiegazione o possibilità da verificare.

Può diventare importante, ma non è ancora una regola o un fatto consolidato.

Proposta

Una proposta suggerisce una possibile scelta.

Può richiedere valutazione o approvazione, ma non modifica automaticamente la baseline.


Decisione

Una decisione, quando proviene dall'autorità appropriata e ha forza materiale, cambia ciò che l'organizzazione deve considerare valido o fare successivamente.

Questa progressione può essere rappresentata così:

RIFLESSIONE

|



Ma attenzione: non è una pipeline obbligatoria.

Una riflessione non deve necessariamente diventare ipotesi. Una proposta può essere rifiutata. Una decisione può essere presa senza aver percorso tutte le fasi in modo esplicito.

La figura serve soltanto a mostrare che **la forza organizzativa aumenta**.

Il compito della Working Memory è mantenere la sfumatura abbastanza a lungo da non confondere questi livelli.

Il compito del consolidamento è preservare nella memoria persistente il livello corretto.

Questo evita due failure molto diverse:

PROPOSTA → salvata come DECISIONE

che crea falsa authority;

oppure:

DECISIONE → lasciata come semplice frase di chat

che crea perdita di continuità.

4.8 Una nuova decisione nella Working Memory non sostituisce da sola la memoria persistente

Supponiamo che nella memoria persistente esista una decisione attiva:

DECISIONE CORRENTE = X

Durante una conversazione qualcuno dice:

■ «Potremmo fare Y.»

La Working Memory contiene ora X, richiamata dal passato, e la nuova proposta Y.

Non esiste una contraddizione da “risolvere” sostituendo automaticamente X.

Esistono due elementi con status diversi:

X = decisione attiva
Y = proposta corrente

Se successivamente l'authority competente dice:

■ «Ho deciso: da ora facciamo Y.»

allora nasce un delta materiale.

A quel punto WCM deve:

1. riconoscere che non si tratta più di una proposta;
2. verificare l'authority;
3. preservare il **lineage**, cioè la storia e il collegamento tra la decisione precedente e quella nuova;
4. valutare gli impatti;
5. consolidare la nuova decisione nella fonte persistente appropriata;
6. aggiornare i nodi che dipendono materialmente dal cambiamento.

La Working Memory è quindi il luogo nel quale nasce il nuovo significato.

La memoria persistente è il luogo nel quale quel significato diventa durevole e governabile quando possiede i requisiti per esserlo.

4.9 La Working Memory durante il bootstrap di una nuova richiesta

C'è un altro punto importante: WCM non deve ignorare ciò che sa già soltanto perché possiede una memoria persistente.

Quando arriva una nuova richiesta, il **bootstrap del contesto** — la fase iniziale in cui WCM ricostruisce ciò che deve sapere prima di agire — deve partire da una domanda semplice:

Quale contesto pertinente e affidabile è già disponibile nella Working Memory?

Se stiamo continuando una conversazione nella quale goal, vincoli e riferimenti sono già chiari, rileggere gli stessi documenti per rituale sarebbe inefficiente.


Ma esistono informazioni che richiedono verifica persistente anche quando la Working Memory sembra ricordarle bene.

Per esempio:

- authority;
- decisioni **frozen** o attive — dove **frozen** indica una decisione approvata e congelata come riferimento corrente finché non interviene un cambiamento governato;
- stato operativo corrente;
- workflow persistenti da riprendere;
- contratti o vincoli che possono essere cambiati;
- processi e protocolli applicabili quando il task è sensibile.

Il comportamento WCM è quindi:

```
CONTESTO VIVO PERTINENTE?  
  |  
  v  
USALO  
  |  
  v  
SERVE VERIFICA / MANCA QUALCOSA?
```



Il principio è **context-aware**, non “chat-first” e non “repository-first” in senso assoluto.

La Working Memory riduce letture ridondanti.

La memoria persistente impedisce che la comodità del contesto vivo sostituisca l'autorità organizzativa.

4.10 La Working Memory non è un'autorizzazione

Un'AI può comprendere perfettamente una richiesta e avere tecnicamente la capacità di eseguirla.

Questo non significa che la Working Memory possa creare authority da sola.

Ricordiamo la distinzione del Capitolo 2:

CAPABILITY = posso tecnicamente farlo
AUTHORITY = sono autorizzato a farlo

Il fatto che una persona abbia scritto qualcosa nella conversazione può essere rilevante per l'autorità, ma la semantica dipende dal contratto di governance applicabile.

Una frase come:

«Vai pure.»

può costituire authority sufficiente in un contesto e non esserlo in un altro.

WCM non può decidere in astratto che qualunque frase imperativa equivalga a una decisione autorizzata.

Per questo, sui passaggi sensibili, la Working Memory viene combinata con:

- identità;
- ruolo;
- governance;
- stato;
- eventuale gate;
- processi e protocolli applicabili.

La memoria viva aiuta a comprendere l'intenzione.

La governance stabilisce se quell'intenzione possiede la forza per produrre l'effetto richiesto.

4.11 Quando qualcosa deve sopravvivere alla sessione

Possiamo ora formulare una domanda pratica che accompagnerà tutto il resto del libro:

Se questa conversazione terminasse adesso, una futura ripresa del lavoro avrebbe bisogno di questa informazione per continuare correttamente?

Se la risposta è sì, il contenuto è candidato al consolidamento.

Non significa che debba essere copiato letteralmente.

Significa che WCM deve chiedersi **che cosa** deve sopravvivere e **in quale forma**.

Esempio:

Durante una lunga discussione vengono valutate cinque alternative e alla fine viene approvata la terza.

La futura organizzazione potrebbe non avere bisogno dell'intera discussione.

Potrebbe aver bisogno di:

- decisione finale;
- authority;
- motivazione essenziale se rilevante;
- decisione precedente eventualmente sostituita;
- vincoli che hanno determinato la scelta;
- impatti sui nodi dipendenti.

Quindi il passaggio corretto non è:

```
CONVERSAZIONE IMPORTANTE  
→ SALVA LA CONVERSAZIONE
```

ma:

```
CONVERSAZIONE  
→ COSA È CAMBIATO?  
→ CHE TIPO DI DELTA È?  
→ DEVE SOPRAVVIVERE?  
→ DOVE APPARTIENE?  
→ CONSOLIDA  
→ VERIFICA COERENZA
```

Questo è il cuore di **PROC-006 Memory Consolidation & Consistency Loop**, che verrà approfondito nel Capitolo 6.

4.12 La regola del costo proporzionato

Una possibile reazione a questi principi sarebbe trasformare ogni frase in un procedimento amministrativo.

Sarebbe un errore.

WCM non richiede di aprire un record formale dopo ogni messaggio.

Il processo di consolidamento stesso stabilisce che non deve essere applicato come rituale dopo ogni interazione.

Il costo documentale deve essere proporzionato alla materialità del delta.

Possiamo pensare a tre livelli intuitivi.

Livello 1 — Effimero

Non cambia futuro, stato o authority.

Esempi:

- prova di una formulazione;
- ragionamento locale;
- domanda immediatamente risolta;
- dettaglio utile soltanto alla frase successiva.

Normalmente resta nella Working Memory.

Livello 2 — Rilevante

Può essere utile oltre il momento, ma non modifica necessariamente una baseline autorevole.

Esempi:

- rischio emerso;
- requisito candidato;
- evidenza nuova;
- assunzione che condiziona il lavoro.

Richiede classificazione e può richiedere consolidamento.

Livello 3 — Materiale / autorevole

Modifica ciò che l'organizzazione deve sapere o fare.

Esempi:

- decisione autorizzata;
- cambio di stato;
- checkpoint di workflow;
- output frozen;
- modifica di un vincolo importante;
- authority persistente.

Non deve essere affidato soltanto alla Working Memory.

Questa distinzione non è un nuovo protocollo né una tassonomia canonica obbligatoria del WCM. È una **mappa pedagogica** per comprendere il principio di proporzionalità già presente nel Memory Consolidation Loop.

4.13 Cosa succede se Working Memory e memoria persistente sembrano dire cose diverse

Un'apparente contraddizione non va risolta “a intuito”.

Prima dobbiamo capire la natura dei due elementi.

Caso A:

```
PERSISTENT MEMORY
Decisione attiva: X

WORKING MEMORY
“Potremmo valutare Y”
```

Non c'è conflitto.

X resta attiva; Y è una proposta.

Caso B:

```
PERSISTENT MEMORY
Decisione attiva: X

WORKING MEMORY
Authority competente: “Da ora decidiamo Y”
```

Qui esiste un nuovo delta decisionale da consolidare e propagare con lineage e impact analysis.

Caso C:

```
PERSISTENT MEMORY
Stato strutturato: WAITING_AUTHORITY

WORKING MEMORY
Sintesi testuale precedente: “possiamo continuare”
```

Se esiste uno stato strutturato autorevole per l'esecuzione, WCM non deve reinterpretarlo creativamente sulla base di una frase testuale **stale**, cioè non più aggiornata rispetto alla fonte corrente.

Il punto generale è:

Working Memory e Persistent Memory non si votano a maggioranza. Il sistema deve classificare contenuto, status, source of truth e authority.

4.14 I principali failure mode della Working Memory

Capire la Working Memory significa capire anche come può essere usata male.

Failure 1 — “È nella chat, quindi è salvo”

Una decisione materiale viene ricordata durante la sessione ma non consolidata.
La sessione successiva non può ricostruirla con sufficiente affidabilità.

Failure 2 — “Se l'AI lo ricorda, è autorevole”

La memoria del sistema contiene un'informazione corretta ma non più corrente oppure priva della necessaria authority.

Ricordare qualcosa non la rende automaticamente source of truth.

Failure 3 — Proposta trasformata in decisione

Una possibilità discussa viene persistita o eseguita come se fosse stata approvata.

Failure 4 — Decisione trattata come semplice conversazione

L'errore opposto: una decisione vera resta confinata nel contesto vivo.

Failure 5 — Full reload inutile

Il sistema ignora un contesto corrente ricco e rilegge tutto indiscriminatamente dalla memoria persistente.

Failure 6 — Nessun retrieval quando serve verifica

Il sistema si affida alla Working Memory anche per authority, stato o baseline sensibili che potrebbero essere cambiati.

Failure 7 — Consolidamento eccessivo

Ogni frase diventa memoria persistente, producendo rumore, duplicazioni e una knowledge base difficile da navigare.

La Working Memory funziona bene quando viene usata per ciò che sa fare meglio: mantenere il significato vivo mentre il lavoro è in corso.

4.15 La Working Memory come spazio di libertà cognitiva governata

A questo punto possiamo descrivere il suo ruolo in modo più preciso.

La Working Memory è lo spazio nel quale il sistema può:

- esplorare;
- confrontare alternative;
- chiedere chiarimenti;

- formulare ipotesi;
- rivedere una posizione;
- comprendere intenzioni;
- combinare fonti richiamate dalla memoria persistente;
- costruire una nuova proposta;
- preparare una decisione;
- eseguire ragionamento contestuale.


Questa libertà è importante.

Se ogni pensiero dovesse diventare immediatamente una modifica persistente, il sistema sarebbe rigido e rumoroso.

Ma la libertà non è anarchia organizzativa.

Quando il ragionamento produce un delta che deve influenzare il futuro, entra in gioco il consolidamento.

Possiamo quindi sintetizzare il confine così:



Il valore della Working Memory non deriva dal fatto che sostituisca le regole.

Deriva dal fatto che consente alla cognizione di rimanere ricca **senza obbligare l'organizzazione a essere volatile**.

4.16 Dove siamo arrivati

Possiamo chiudere il capitolo con otto idee essenziali.

1. **Working Memory è il contesto vivo del lavoro cognitivo corrente.**
2. Non coincide con la sola trascrizione della chat: comprende relazioni, intenzioni, chiarimenti e contesto operativo disponibile.
3. È semanticamente ricca proprio perché può contenere elementi ancora fluidi e non strutturati.
4. È temporanea nel senso organizzativo: WCM non può garantire che resti disponibile indefinitamente nella stessa forma.
5. Ragionamenti effimeri possono restare nella Working Memory.
6. Decisioni, stato, authority, checkpoint e altri delta materiali non devono dipendere soltanto da essa.

7. Riflessione, ipotesi, proposta e decisione devono essere distinte prima del consolidamento.
8. Il principio corretto non è “salvare tutto”, ma **consolidare ciò che deve sopravvivere**.

Nel prossimo capitolo apriremo l'altro lato della Dual Memory: la **Persistent Organizational Memory**.

Vedremo non soltanto dove WCM conserva ciò che deve durare, ma soprattutto come quella memoria viene organizzata affinché non diventi un semplice deposito di file.

Source Map — Frozen 04

Fonti canoniche principali usate per questa stesura:

- [wcm/kb/decisions/DEC-004_DUAL_MEMORY_CAUSAL_DECISION_BASELINE.md](#) — principio Dual Memory FROZEN e complementarità delle due memorie;
- [wcm/kb/concepts/CONCEPT-008_DUAL_MEMORY_COGNITIVE_CONTINUITY.md](#) — definizione e caratteristiche della Working Memory, context-aware retrieval e classificazione dei delta;
- [wcm/process-book/processes/PROC-005_AGENT_READY_CONTEXT_BOOTSTRAP.md](#) — uso della Working Memory pertinente nel bootstrap e verifica persistente quando necessaria;
- [wcm/process-book/processes/PROC-006_MEMORY_CONSOLIDATION_LOOP.md](#) — trigger di consolidamento, classificazione, authority/status check e destinazioni dei delta;
- [wcm/kb/concepts/CONCEPT-009_DECISION_LINEAGE_CAUSAL_IMPACT.md](#) — distinzione tra nuova proposta e cambio decisionale materiale;
- [wcm/kb/decisions/DEC-012_SESSION_INDEPENDENT_WORKFLOW_EXECUTION.md](#) — necessità di checkpoint persistenti per workflow che attraversano le sessioni;
- [wcm/kb/decisions/DEC-013_DETERMINISTIC_OPERATIONAL_STATE_PIPELINE.md](#) — structured-before-text e prevalenza dello stato esecutivo strutturato quando applicabile.

Figure collegate

- [FIG-001A_DUAL_MEMORY_SIMPLE.svg](#) — APPROVED / riusata per orientare il lettore nel ciclo Dual Memory.
- [FIG-001B_DUAL_MEMORY_ARCHITECTURE.svg](#) — APPROVED / riferimento architettuale; non necessariamente ripetuta integralmente nel PDF se ridondante.

Review closure

- [reviews/CH04_TECHNICAL_REVIEW.md](#) — PASS;
- [reviews/CH04_HUMAN_COMPREHENSION_REVIEW.md](#) — PASS;
- Working Memory definita come contesto vivo disponibile, non memoria proprietaria/privata di uno specifico LLM;
- temporaneità organizzativa distinta dalla durata cronologica;

- proposta / decisione / authority distinte;
- scala Effimero / Rilevante / Materiale dichiarata esplicitamente pedagogica e non canonica;
- FIG-001A riusata senza modifica semantica;
- FIG-001B resta riferimento architettuale già approvato;
- nessun riferimento project-specific nel capitolo.

Freeze verdict: CHAPTER 04 FROZEN – 2026-08-26.